

Identificação de Fatores Associados à Doença Pulmonar Obstrutiva Crônica em Idosos Brasileiros e seu perfil nutricional: Uma Abordagem com Dados da PNS 2019

Walker Junio Gonzaga Rocha

Resumo

Este trabalho analisa fatores associados à Doença Pulmonar Obstrutiva Crônica (DPOC) em idosos brasileiros, utilizando técnicas de aprendizado de máquina aplicadas aos microdados da Pesquisa Nacional de Saúde (PNS) de 2019. Inicialmente, foram selecionados 21.968 indivíduos com 60 anos ou mais, dos quais 582 (2,65%) relataram diagnóstico médico de DPOC. Após as etapas de limpeza e remoção de registros incompletos nas variáveis usadas nos modelos, a base de modelagem ficou com 19.417 registros. A seleção de atributos foi feita com Information Gain de Shannon antes do balanceamento das classes, mantendo 14 variáveis preditoras com limiar $IG \geq 0,0003$. Na etapa inicial, foram treinados modelos de Árvore de Decisão e Random Forest com Random Under-Sampling (RUS) apenas no conjunto de treino. Em uma etapa complementar, foi incluído o Balanced Random Forest e foram testados diferentes limiares de decisão, mantendo o conjunto de teste com a distribuição original. O Random Forest com limiar 0,4 obteve o melhor F1-score para a classe DPOC=1 (0,2462), com precisão de 0,2892, recall de 0,2143 e AUC-ROC de 0,7156. O Balanced Random Forest apresentou a maior AUC-ROC (0,7189), indicando desempenho ligeiramente superior na discriminação geral entre indivíduos com e sem DPOC. As variáveis mais relevantes foram Q074 (asma/bronquite asmática), IMC, peso (P00104), idade (C008) e consumo de frutas (P018).

1. Introdução

A Doença Pulmonar Obstrutiva Crônica (DPOC) é uma condição respiratória progressiva, caracterizada pela limitação persistente do fluxo de ar nos pulmões. Ela está fortemente relacionada ao tabagismo, mas também pode estar associada à exposição à poluição, poeiras ocupacionais e outros fatores individuais (GOLD, 2023). Por se tratar de uma doença crônica, a DPOC pode afetar a qualidade de vida dos pacientes e gerar maior demanda por acompanhamento nos serviços de saúde.

No Brasil, a DPOC tem importância especial na população idosa, pois o envelhecimento aumenta a ocorrência de doenças crônicas e a necessidade de cuidados contínuos. Apesar disso, muitos casos podem não ser identificados de forma adequada, principalmente quando não há acesso fácil à espirometria, exame utilizado para confirmar o diagnóstico.

Nesse cenário, técnicas de aprendizado de máquina podem ser utilizadas como uma forma complementar de análise, buscando padrões em bases de dados já existentes. A Pesquisa Nacional de Saúde (PNS) de 2019, conduzida pelo IBGE em parceria com o Ministério da Saúde, reúne informações sobre saúde, hábitos de vida, características sociais e uso de serviços de saúde, sendo uma fonte adequada para estudos exploratórios com dados populacionais.

O objetivo deste trabalho é aplicar modelos de Árvore de Decisão, Random Forest e Balanced Random Forest para identificar fatores associados ao diagnóstico autorreferido

de DPOC em idosos brasileiros, usando os microdados da PNS 2019. Uma escolha importante do estudo foi aplicar o Information Gain antes do balanceamento das classes. Dessa forma, a seleção das variáveis foi feita considerando a base em sua distribuição original, e não uma base modificada artificialmente.

Este artigo está organizado da seguinte forma: a Seção 2 apresenta os trabalhos relacionados; a Seção 3 descreve os materiais e métodos utilizados; a Seção 4 mostra a análise exploratória e a seleção das variáveis; a Seção 5 apresenta os resultados dos modelos; a Seção 6 discute os principais achados; e a Seção 7 apresenta a conclusão, as limitações e sugestões para trabalhos futuros.

2. Trabalhos Relacionados

O uso de aprendizado de máquina em doenças respiratórias crônicas tem sido estudado em diferentes contextos. Exarchos et al. (2014), por exemplo, utilizaram Árvore de Decisão em dados clínicos e espirométricos relacionados à DPOC, mostrando que esse tipo de modelo pode ajudar na construção de regras de decisão. A principal diferença em relação ao presente estudo é que aqui foram usados dados de inquérito populacional, e não dados hospitalares ou exames clínicos.

Kohansal et al. (2009), em estudo longitudinal, identificaram fatores como tabagismo, baixo IMC e exposição ocupacional como associados ao declínio da função pulmonar. Esses achados ajudam a justificar a presença de variáveis como peso, IMC e tabagismo neste trabalho. No contexto brasileiro, Oliveira et al. (2021) utilizaram dados da PNS 2013 e modelos estatísticos para analisar autopercepção de saúde em idosos, mostrando que informações autorreferidas podem ser úteis em estudos de saúde pública.

Quanto à seleção de atributos, Mitchell (1997) apresenta o Information Gain como uma medida baseada em entropia, usada para avaliar o quanto uma variável reduz a incerteza sobre a variável-alvo. Biau e Scornet (2016) discutem o funcionamento do Random Forest, enquanto He e Garcia (2009) destacam cuidados necessários em bases desbalanceadas. Chawla et al. (2002) propõem o SMOTE como alternativa de balanceamento, sendo uma possibilidade para estudos futuros.

Como extensão dos modelos baseados em árvores, o Balanced Random Forest também pode ser aplicado em cenários de forte desbalanceamento, pois incorpora o balanceamento das classes durante a construção das árvores. Essa abordagem é adequada para problemas em que a classe positiva é rara, como ocorre neste estudo com os casos autorreferidos de DPOC.

Assim, este trabalho se aproxima desses estudos por usar modelos interpretáveis e métricas adequadas para dados desbalanceados, mas se diferencia por focar especificamente em idosos brasileiros com dados da PNS 2019 e por aplicar a seleção de variáveis antes do balanceamento.

3. Materiais e Métodos

3.1 Fonte de Dados

Os dados utilizados foram obtidos dos microdados da Pesquisa Nacional de Saúde (PNS) de 2019, disponibilizados pelo IBGE. A PNS é um pesquisa domiciliar de

abrangência nacional que coleta informações sobre saúde, hábitos de vida, utilização de serviços e características socioeconômicas da população brasileira. Neste estudo, foram selecionados registros de indivíduos com 60 anos ou mais. Após essa primeira filtragem e a seleção inicial das variáveis de interesse, a base ficou com 21.968 idosos.

3.2 Variável Alvo

A variável dependente foi o diagnóstico autorreferido de DPOC, derivado da variável Q11604 da PNS, que pergunta se o entrevistado já recebeu diagnóstico médico de bronquite crônica, enfisema pulmonar ou DPOC. A variável foi transformada em formato binário, sendo DPOC =1 para diagnóstico positivo e DPOC = 0 para ausência do diagnóstico. Na base inicial de idosos, 582 indivíduos (2,65%) relataram DPOC e 21.386 (97,35%) não relataram a doença.

3.3 Variáveis Independentes e Dicionário de Dados

As variáveis preditoras foram escolhidas considerando fatores que aparecem na literatura sobre DPOC e que também estavam disponíveis na PNS 2019.

Além das variáveis originais, foram criadas três variáveis derivadas: IMC, calculado a partir do peso (P00104) e da altura (P00404); CONSUMO_FLV, formado pela soma do consumo semanal de frutas e verduras/legumes (P018 + P00901); e FAIXA_ETARIA, criada a partir da idade (C008), em faixas decenais.

Tabela 1 — Dicionário de variáveis utilizadas no modelo (PNS 2019)

Variável	Tipo	Pergunta / Descrição (PNS 2019)	Domínio	Categorias / Observações
Q11604	Binária	Diagnóstico médico autorreferido de DPOC / bronquite crônica / enfisema pulmonar	Condição-alvo	Variável dependente; DPOC=1 (Sim) / DPOC=0 (Não)
Q074	Binária	Diagnóstico médico autorreferido de asma ou bronquite asmática	Histórico respiratório	1=Sim; 2=Não
Q00201	Binária	Diagnóstico médico autorreferido de hipertensão arterial	Morbidade crônica	1=Sim; 2=Não
Q03001	Binária	Diagnóstico médico autorreferido de diabetes	Morbidade crônica	1=Sim; 2=Não
P00104	Contínua (kg)	Peso final aferido ou autorreferido	Antropométrica	Usado para cálculo do IMC
P00404	Contínua (cm)	Altura final aferida ou autorreferida	Antropométrica	Usado para cálculo do IMC
P018	Discreta (0–7)	Dias/semana em que come frutas	Alimentação	0=nunca; 1–7=dias; compõe CONSUMO_FLV
P00901	Discreta (0–7)	Dias/semana em que come verduras ou legumes	Alimentação	0=nunca; 1–7=dias; compõe CONSUMO_FLV
P02002	Discreta (0–7)	Dias/semana em que toma refrigerante	Alimentação	0=nunca; 1–7=dias
P02501	Discreta (0–7)	Dias/semana em que come alimentos doces	Alimentação	Biscoito, chocolate, balas; 0=nunca; 1–7=dias
P050	Categ. (1–3)	Situação atual de tabagismo	Tabagismo	1=Fuma diariamente; 2=Menos que diariamente; 3=Não fuma
P051	Binária	Fumou diariamente no passado	Tabagismo	1=Sim; 2=Não; apenas para quem respondeu P050=3
P034	Binária	Praticou exercício físico nos últimos 3 meses	Atividade física	1=Sim; 2=Não
P035	Discreta (0–7)	Dias/semana que pratica exercício físico	Atividade física	0=nunca; 1–7=dias
C006	Binária	Sexo do morador	Sociodemográfica	1=Homem; 2=Mulher
C008	Contínua (anos)	Idade do morador (anos completos)	Sociodemográfica	Range 60–107; base para FAIXA_ETARIA
C009	Categ. (1–5)	Cor ou raça autodeclarada	Sociodemográfica	1=Branca; 2=Preta; 3=Amarela; 4=Parda; 5=Indígena
VDD004A	Ordinal (1–7)	Nível de instrução mais elevado alcançado	Escolaridade	1=Sem instrução; ... 7=Superior completo

J01101	Ordinal (1–5)	Última vez que consultou um médico	Utilização de serviços	1=Até 1 ano; ... 5=Nunca
J012	Discreta	Número de consultas médicas nos últimos 12 meses	Utilização de serviços	Contagem direta
IMC	Contínua (kg/m ²)	Índice de Massa Corporal (derivado de P00104 e P00404)	Derivada — antropométrica	IMC = Peso / Altura ² ; range 11,1–52,9
IMC_CLASSE	Categ.	Classificação do IMC em categorias	Derivada — antropométrica	Baixo_peso (<22 kg/m ²); Eutrófico; Sobrepeso
CONSUMO_FLV	Discreta (0–14)	Escore de consumo semanal de frutas, legumes e verduras	Derivada — alimentação	P018 + P00901; range 0–14
FAIXA_ETARIA	Categ.	Faixas etárias decenais derivadas de C008	Derivada — sociodemográfica	60–64; 65–69; 70–74; 75–79; 80+

3.4 Modelo Conceitual

A Figura 1 apresenta o modelo conceitual usado para organizar as variáveis do estudo. O diagrama coloca a DPOC em idosos brasileiros no centro e relaciona a doença a seis grupos de fatores: hábitos de saúde, hábitos alimentares, antropometria, condições clínicas, dados sociodemográficos e acesso/uso de serviços de saúde.

Esse modelo conceitual foi usado como apoio para organizar a análise. Algumas informações do diagrama aparecem diretamente na PNS 2019, como tabagismo, consumo alimentar, idade, sexo, peso, IMC e doenças autorreferidas. Outras, como inflamação pulmonar, síndrome ACOS e acesso à espirometria, foram mantidas apenas com base em referências literárias (conhecimento explícito), pois não foram medidas diretamente na base utilizada.




Figura 1 — Modelo conceitual: dimensões e fatores associados à DPOC em idosos brasileiros. Fonte: Elaborado pelo autor.

3.5 Pré-processamento

O pré-processamento foi realizado em etapas. Primeiro, foram filtrados os indivíduos com 60 anos ou mais. Em seguida, foram selecionadas as variáveis de interesse listadas na Tabela 1. Depois, foram removidos registros com valores ausentes nas variáveis usadas nos modelos, codificadas as variáveis categóricas e criadas as variáveis derivadas IMC,

CONSUMO_FLV e FAIXA_ETARIA. Com isso, a base passou de 21.968 idosos na seleção inicial para 19.417 registros efetivamente utilizados na modelagem.

Também foi feita uma verificação simples de valores extremos nas variáveis antropométricas, principalmente peso, altura e IMC. Essa etapa teve o objetivo de observar se existiam valores muito fora do esperado, que poderiam indicar erro de preenchimento ou inconsistência na base.

3.6 Seleção de Atributos por Information Gain

A seleção de atributos foi feita com Information Gain (IG) de Shannon. Essa etapa foi realizada depois do pré-processamento e antes da divisão treino/teste e do balanceamento. Foi feito isso porque o objetivo era avaliar a relação das variáveis com a DPOC na base real, ainda desbalanceada, evitando que o balanceamento influenciasse a escolha das variáveis.

O Information Gain mede a redução de incerteza (entropia) que uma variável preditora proporciona em relação à variável alvo. Para uma variável X e a variável alvo Y :

$$IG(Y, X) = H(Y) - H(Y | X)$$

onde $H(Y)$ representa a entropia da variável-alvo e $H(Y | X)$ representa a entropia condicional. A entropia da variável DPOC, calculada na base de 19.417 registros, foi $H(DPOC) = 0,188021$ bits. Esse valor baixo ocorre porque a maior parte dos registros pertence à classe sem DPOC. Foi adotado o limiar $IG \geq 0,0003$ para manter as variáveis com maior contribuição relativa para a classificação.

3.7 Divisão dos Dados e Tratamento do Desbalanceamento

Após a seleção de atributos, os dados foram divididos em treino (80%) e teste (20%), mantendo a proporção original das classes. Como apenas 2,87% dos registros da base modelada eram positivos para DPOC, foi aplicado Random Under-Sampling (RUS) somente no conjunto de treino na etapa inicial dos modelos. Assim, o treino ficou balanceado com 932 registros, sendo 466 positivos e 466 negativos. O conjunto de teste foi mantido sem balanceamento para avaliar os modelos em uma situação mais próxima da base original.

Além da avaliação inicial com RUS, foi realizada uma etapa complementar sem alterar o conjunto de teste, comparando Árvore de Decisão, Random Forest e Balanced Random Forest. Nessa etapa, também foram testados diferentes limiares de decisão para avaliar o equilíbrio entre recall, precisão, F1 score e AUC ROC da classe DPOC=1.

3.8 Modelos de Classificação e Otimização

Foram treinados três modelos de classificação: Árvore de Decisão (DT), Random Forest (RF) e Balanced Random Forest (BRF). A Árvore de Decisão foi escolhida por permitir uma interpretação mais direta das regras geradas. O Random Forest foi utilizado por combinar várias árvores de decisão e, em geral, apresentar melhor capacidade de classificação. O Balanced Random Forest foi adicionado como modelo complementar por lidar bem com as bases desbalanceadas, realizando amostragens balanceadas durante a construção das árvores.

Hiperparâmetros finais selecionados na etapa inicial:

Árvore de Decisão: `criterion = 'gini'`, `max_depth = 5`, `min_samples_split = 2`, `min_samples_leaf = 10`.

Random Forest: `n_estimators = 50`, `criterion = 'gini'`, `max_depth = None`, `max_features = 'log2'`, `min_samples_split = 10`, `min_samples_leaf = 2`.

Random Forest foi ajustado com 200 árvores e `class_weight = 'balanced'`, enquanto o Balanced Random Forest foi treinado com 300 árvores, `sampling_strategy = 'auto'` e `replacement = True`.

3.9 Avaliação dos Modelos

Como a base é muito desbalanceada, a acurácia sozinha não foi o suficiente para avaliar os modelos. Por isso, foram consideradas métricas como F1-Score, Precisão, Recall, AUC ROC e matriz de confusão. A curva ROC também foi usada para comparar a capacidade dos modelos em separar os casos com e sem DPOC. Na análise complementar, diferentes limiares de decisão foram avaliados, pois o limiar padrão de 0,5 nem sempre produz o melhor equilíbrio em bases com classe positiva rara.

As métricas foram calculadas no conjunto de teste, que foi mantido com a distribuição original das classes. Neste estudo, os intervalos de confiança não foram estimados, pois o foco principal foi comparar o comportamento dos modelos e dos limiares de decisão. Essa ausência é uma limitação da avaliação e pode ser tratada em trabalhos futuros.

4. Análise de Entropia e Exploratória das Variáveis

4.1 Distribuição da Variável Alvo

Na base usada para modelagem, após a limpeza dos dados, havia 19.417 registros. Desses, 558 indivíduos (2,87%) relataram diagnóstico de DPOC e 18.859 (97,13%) não relataram. Essa diferença entre as classes mostra o forte desbalanceamento da variável alvo. A entropia de Shannon calculada foi $H(\text{DPOC}) = 0,188021$ bits, valor baixo por causa da concentração de registros na classe negativa.

4.2 Seleção de Variáveis por Information Gain

O IG foi calculado para as 23 variáveis candidatas em relação à variável-alvo DPOC. A Figura 2 mostra os valores encontrados, com a linha tracejada vermelha indicando o ponto adotado (IG = 0,0003).




Figura 2 — Information Gain das variáveis preditoras em relação à DPOC. Fonte: Elaborado pelo autor.

A variável Q074, referente ao diagnóstico autorreferido de asma ou bronquite asmática, foi a que apresentou maior Information Gain, com $IG = 0,01543$. Esse valor ficou bem acima das demais variáveis e correspondeu a 8,21% da entropia total da variável-alvo. Esse resultado é coerente com a relação clínica entre asma, bronquite e DPOC.

A Tabela 2 apresenta os valores de IG para todas as variáveis avaliadas, em ordem decrescente.

Tabela 2 — Information Gain das variáveis preditoras em relação à DPOC

Variável	IG	IG (%)
Q074	0,015434	8,21%
IMC	0,001863	0,99%
FAIXA_ETARIA	0,001272	0,68%
P035	0,001247	0,66%
C008	0,001209	0,64%
IMC_CLASSE	0,001127	0,60%
P02501	0,000953	0,51%
P034	0,000912	0,48%
P018	0,000791	0,42%
C009	0,000768	0,41%
P00104	0,000719	0,38%
P00901	0,000591	0,31%
P050	0,000473	0,25%
P02002	0,000313	0,17%
VDD004A	0,000261	0,14%
CONSUMO_FLV	0,000189	0,10%
C006	0,000187	0,10%
P00404	0,000155	0,08%
J012	0,000137	0,07%
P051	0,000071	0,04%
Q00201	0,000060	0,03%

Q03001	0,000002	0,00%
J01101	0,000000	0,00%

Com base no limiar $IG \geq 0,0003$, foram mantidas 14 variáveis: Q074, IMC, FAIXA_ETARIA, P035, C008, IMC_CLASSE, P02501, P034, P018, C009, P00104, P00901, P050 e P02002.

Foram removidas 9: VDD004A, CONSUMO_FLV, C006, P00404, J012, P051, Q00201, Q03001 e J01101.

Um ponto importante da seleção foi a remoção da variável J012, que diz sobre o número de consultas médicas. Apesar de essa variável poder parecer relevante, seu IG foi de apenas 0,000137 na base original. Isso indica que sua contribuição para diferenciar casos com e sem DPOC foi pequena nesse conjunto de dados. O mesmo ocorreu com VDD004A (escolaridade) e P00404 (altura), que também ficaram abaixo do limiar definido.

4.3 Análise Exploratória das Variáveis Mantidas

Entre as variáveis mantidas, Q074 apresentou grande destaque por representar histórico respiratório autorreferido. O IMC e o peso também apareceram entre as variáveis relevantes, o que é compatível com a relação entre estado nutricional e doenças respiratórias crônicas em idosos. As variáveis de atividade física (P034 e P035) também foram mantidas, indicando que hábitos de saúde podem contribuir para diferenciar os grupos. FAIXA_ETARIA e C008 reforçam a influência da idade na ocorrência de DPOC.

5. Resultados

5.1 Desempenho dos Modelos

A Tabela 3 apresenta as métricas de avaliação obtidas no conjunto de teste para os dois modelos da etapa inicial, treinados sobre as 14 variáveis selecionadas pelo Information Gain.

Tabela 3 — Métricas de avaliação dos modelos no conjunto de teste

Métrica	Árvore de Decisão	Random Forest	Observação
Acurácia	0,788	0,742	Reflexo do desbalanceamento
F1-Score (DPOC=1)	0,126	0,118	Baixo — desbalanceamento extremo
F1-Score (macro)	0,503	0,483	DT com melhor equilíbrio geral
Precisão (DPOC=1)	0,071	0,065	Muitos FP — alta sensibilidade
Recall (DPOC=1)	0,527	0,598	RF detecta mais casos reais
AUC-ROC	0,681	0,721	RF superior em discriminação
VP — DPOC corretamente identificado	59	67	RF: +13,6% de verdadeiros positivos
FN — DPOC não detectado	53	45	RF: menos casos perdidos
FP — saudável classificado como DPOC	769	958	Custo do maior recall no RF
VN — saudável corretamente classificado	3003	2814	

VP = Verdadeiro Positivo; FN = Falso Negativo; FP = Falso Positivo; VN = Verdadeiro Negativo.

5.2 Comparação entre os Modelos

Na etapa inicial, os dois modelos apresentaram comportamentos diferentes. O Random Forest teve melhor capacidade de discriminação, com AUC-ROC de 0,721 contra 0,681 da Árvore de Decisão. Também apresentou maior Recall para a classe DPOC = 1, identificando 67 dos 112 casos positivos no conjunto de teste, enquanto a Árvore de Decisão identificou 59 casos. Por outro lado, o Random Forest gerou mais falsos positivos: 958 contra 769 da Árvore de Decisão.

A Árvore de Decisão apresentou maior acurácia global e F1-Score macro, o que indica um resultado mais equilibrado considerando as duas classes. Já o Random Forest foi mais sensível para encontrar casos positivos de DPOC, mesmo classificando mais pessoas sem DPOC como positivas. Em uma análise de triagem, esse comportamento pode ser aceitável, mas depende do objetivo da aplicação e de validações adicionais.

5.3 Matrizes de Confusão

As Figuras 3 e 4 apresentam as matrizes de confusão dos dois modelos. A Árvore de Decisão identificou corretamente 59 dos 112 casos positivos de DPOC no conjunto de teste, com 53 falsos negativos. O Random Forest identificou 67 casos positivos e reduziu os falsos negativos para 45. Essa diferença mostra que o RF conseguiu capturar mais casos de DPOC, embora tenha aumentado o número de falsos positivos.




Figura 3 - Matriz de Confusão: Árvore de Decisão. Fonte: Elaborado pelo autor.




Figura 4 — Matriz de Confusão: Random Forest. Fonte: Elaborado pelo autor.

5.4 Curvas ROC

A Figura 5 apresenta as curvas ROC dos dois modelos, comparadas ao classificador aleatório (AUC = 0,500). O Random Forest apresentou AUC = 0,721, enquanto a Árvore de Decisão apresentou AUC = 0,681. Assim, o RF teve melhor desempenho geral na separação entre indivíduos com e sem DPOC, embora a diferença não elimine a importância da Árvore de Decisão como modelo interpretável.




Figura 5 - Curvas ROC: Árvore de Decisão (AUC = 0,681) vs. Random Forest (AUC = 0,721). Fonte: Elaborado pelo autor.

5.5 Importância dos Atributos (Random Forest)

A Figura 6 e a Tabela 4 apresentam a importância média dos atributos no modelo Random Forest, calculada por Mean Decrease in Impurity (MDI). As variáveis com maior importância foram Q074(0,2706), IMC(0,1374), P00104/peso (0,1127), C008/idade (0,0955) e P018/consumo de frutas (0,0663). Essa ordem é parecida com a observada no Information Gain, principalmente pela presença de Q074 e IMC entre as primeiras posições.




Figura 6 — Importância dos atributos: Random Forest .Fonte: Elaborado pelo autor.

Tabela 4 — Top 10 atributos por importância MDI (Random Forest)

Atributo	Importância (MDI)	Descrição (PNS 2019)
Q074	0,2706	Diagnóstico autorreferido de asma ou bronquite asmática
IMC	0,1374	Índice de Massa Corporal
P00104	0,1127	Peso corporal (kg)
C008	0,0955	Idade do morador (anos completos)
P018	0,0663	Dias/semana em que come frutas
P00901	0,0578	Dias/semana em que come verduras ou legumes
P02501	0,0505	Dias/semana em que come alimentos doces
C009	0,0470	Cor ou raça autodeclarada
FAIXA_ETARIA	0,0450	Faixa etária decenal
P035	0,0351	Dias/semana que pratica exercício físico

5.6 Experimento Complementar com Balanced Random Forest e Ajuste de Limiar

Após a avaliação inicial, foi realizada uma etapa complementar para verificar se os resultados poderiam ser melhorados sem modificar o conjunto de teste. Nessa etapa, foram

comparados três modelos: Árvore de Decisão, Random Forest e Balanced Random Forest. Também foram testados diferentes limiares de decisão, pois em bases muito desbalanceadas o limiar padrão de 0,5 pode não representar o melhor equilíbrio entre sensibilidade e precisão.

A Tabela 5 resume os principais resultados dessa etapa. O melhor F1-score para a classe DPOC=1 foi obtido pelo Random Forest com limiar 0,4, alcançando F1-score de 0,2462, precisão de 0,2892, recall de 0,2143 e AUC-ROC de 0,7156. O Balanced Random Forest apresentou a maior AUC-ROC, com valor de 0,7189, indicando capacidade ligeiramente superior de discriminação geral entre indivíduos com e sem DPOC.

Tabela 5 — Comparação complementar dos modelos com ajuste de limiar

Critério	Modelo e limiar	Métricas principais	Matriz de confusão	Interpretação
Melhor F1	Random Forest Limiar 0,4	Acurácia: 0,9622 Recall: 0,2143 Precisão: 0,2892 F1: 0,2462 AUC: 0,7156	VP: 24 FN: 88 FP: 59 VN: 3713	Melhor equilíbrio entre precisão e recall para DPOC=1.
Melhor AUC	Balanced Random Forest Limiar 0,7	Acurácia: 0,9279 Recall: 0,3482 Precisão: 0,1585 F1: 0,2179 AUC: 0,7189	VP: 39 FN: 73 FP: 207 VN: 3565	Maior capacidade geral de separação das classes.
Melhor Recall	Balanced Random Forest Limiar 0,2	Acurácia: 0,0806 Recall: 0,9821 Precisão: 0,0299 F1: 0,0580 AUC: 0,7189	VP: 110 FN: 2 FP: 3569 VN: 203	Alta sensibilidade, mas muitos falsos positivos.

VP = Verdadeiro Positivo; FN = Falso Negativo; FP = Falso Positivo.

O resultado com maior recall detectou quase todos os casos positivos de DPOC, mas gerou muitos falsos positivos e baixa precisão. Por isso, esse resultado é útil para discutir sensibilidade em um cenário de triagem, mas não foi considerado o melhor equilíbrio geral. Para o resultado final, o Random Forest com limiar 0,4 se destacou pelo maior F1-score, enquanto o Balanced Random Forest se destacou pela maior AUC-ROC.




Figura 7 — Matriz de confusão do melhor resultado por F1-score: Random Forest com limiar 0,4. Fonte: Elaborado pelo autor.




Figura 8 — Matriz de confusão do melhor resultado por AUC-ROC: Balanced Random Forest com limiar 0,7. Fonte: Elaborado pelo autor.




Figura 9 — Curvas ROC: Árvore de Decisão, Random Forest e Balanced Random Forest. Fonte: Elaborado pelo autor.




Figura 10 — Importância dos atributos no Balanced Random Forest. Fonte: Elaborado pelo autor.

A comparação das curvas ROC mostra desempenho próximo entre Random Forest e Balanced Random Forest, com AUC de 0,716 e 0,719, respectivamente. A diferença é

pequena, mas indica que o Balanced Random Forest conseguiu uma separação ligeiramente melhor entre as classes. Na importância dos atributos do Balanced Random Forest, Q074, IMC, P00104, C008 e P018 permaneceram entre as variáveis mais relevantes, reforçando a coerência com a seleção por Information Gain e com a importância observada no Random Forest tradicional.

Considerando o equilíbrio entre precisão, recall e F1-score da classe positiva, o Random Forest com limiar de decisão 0,4 foi considerado o modelo final deste estudo. Mesmo que o Balanced Random Forest tenha apresentado a maior AUC-ROC, o Random Forest teve melhor F1-score para a classe DPOC=1, sendo mais adequado para representar um resultado intermediário entre detectar casos positivos e evitar um número muito alto de falsos positivos.

5.7 Regras da Árvore de Decisão

A Árvore de Decisão, com profundidade máxima 5 e `min_samples_leaf = 10`, gerou regras que ajudam a entender como o modelo separou os grupos. A seguir são apresentadas algumas das principais regras extraídas do modelo treinado com as 14 variáveis selecionadas:

```
|--- Q074 <= 1,50 [com diagnóstico de asma/bronquite asmática]
|   |--- P00104 <= 50,50
|   |   |--- P00104 <= 48,50 → classe: DPOC=1
|   |   |--- P00104 > 48,50 → classe: DPOC=0
|   |--- P00104 > 50,50
|   |   |--- C009 <= 3,50 |--- C008 <= 60,50 → DPOC=1
|   |   |--- C009 <= 3,50 |--- C008 > 60,50 → DPOC=1
|   |   |--- C009 > 3,50 → classe: DPOC=1
|--- Q074 > 1,50 [sem diagnóstico de asma/bronquite asmática]
|   |--- IMC <= 23,75
|   |   |--- C009 <= 2,50 |--- P00104 <= 63,50 |--- IMC <= 20,49 → DPOC=1
|   |   |--- C009 > 2,50 |--- C008 <= 63,50 |--- P018 <= 6,50 → DPOC=1
```

A interpretação das regras deve considerar a codificação original da PNS. Como Q074 foi codificada com 1 = Sim e 2 = Não, o ramo `Q074 <= 1,50` representa indivíduos com diagnóstico autorreferido de asma ou bronquite asmática, enquanto `Q074 > 1,50` representa aqueles sem esse diagnóstico. A presença de Q074 no nó raiz mostra que essa variável foi a principal divisão da árvore. Em seguida, peso, IMC, idade, raça/cor e consumo alimentar aparecem como variáveis usadas para refinar a classificação. É importante observar que essas regras descrevem padrões encontrados no conjunto de treino e não devem ser interpretadas como relações causais.

6. Discussão

6.1 Efeito da Seleção de Atributos por Information Gain

A seleção de atributos por Information Gain antes do balanceamento foi uma escolha importante deste trabalho. Ao calcular o IG na base original, buscou-se avaliar a contribuição das variáveis sem a interferência do balanceamento artificial. Esse procedimento ajudou a remover variáveis com baixa relação com a variável-alvo, como J012 (consultas médicas), P00404 (altura) e VDD004A (escolaridade).

Esse cuidado também reduz o risco de escolher variáveis que parecem importantes apenas depois do balanceamento. Com a retirada de 9 variáveis, os modelos ficaram mais

simples e mais fáceis de interpretar, sem perder as variáveis que apresentaram maior relação com a DPOC na base analisada.

6.2 Capacidade Preditiva e Contexto do Desbalanceamento

Os resultados precisam ser interpretados considerando o forte desbalanceamento da base. Na etapa inicial, o Random Forest apresentou AUC-ROC de 0,721 e maior recall para a classe DPOC=1, identificando mais casos positivos, mas também gerando muitos falsos positivos. Esse comportamento é comum em cenários de triagem, nos quais a sensibilidade pode ser priorizada em relação à precisão.

Na etapa complementar, o Random Forest com limiar 0,4 apresentou o melhor F1-score para a classe positiva (0,2462), melhorando o equilíbrio entre precisão e recall em relação aos resultados iniciais. O Balanced Random Forest obteve a maior AUC-ROC (0,7189), mostrando desempenho ligeiramente superior na capacidade geral de separação das classes. Entretanto, quando o limiar foi reduzido para maximizar o recall, o modelo passou a classificar muitos indivíduos sem DPOC como positivos, reduzindo a precisão. Assim, os resultados mostram que a escolha do modelo e do limiar depende do objetivo da aplicação: triagem com maior sensibilidade ou classificação mais conservadora com menor número de falsos positivos.

6.3 Importância dos Atributos e Coerência Clínica

A comparação entre o Information Gain e a importância MDI do Random Forest e do Balanced Random Forest mostrou resultados próximos, principalmente para as variáveis mais relevantes. Isso reforça que os atributos selecionados tiveram participação consistente nos modelos, mesmo quando foi utilizada uma estratégia específica para lidar com o desbalanceamento.

Q074 (asma/bronquite asmática): foi a variável com maior IG (0,01543; 8,21% da entropia) e também a mais importante no Random Forest (0,2706). Esse resultado indica forte associação entre histórico respiratório autorreferido e DPOC na base analisada.

IMC e P00104 (peso): apareceram entre as variáveis mais importantes do modelo. Essa relação pode estar ligada ao perfil nutricional de idosos com doenças respiratórias crônicas, especialmente em casos com baixo peso ou perda de massa corporal.

Atividade física (P035, P034): as variáveis relacionadas à prática de atividade física foram mantidas pelo IG. Isso sugere que o nível de atividade pode ajudar a diferenciar os grupos, embora não seja possível afirmar causalidade com base em um estudo transversal.

Padrão alimentar (P018, P00901, P02501): essas variáveis apareceram como fatores secundários no modelo. Elas podem refletir hábitos de vida e condições gerais de saúde, mas devem ser interpretadas com cuidado.

Variáveis removidas pelo IG: J012 (consultas médicas), J01101 (última consulta), VDD004A (escolaridade) e P00404 (altura) ficaram abaixo do limiar definido. A exclusão dessas variáveis indica que, nesta base, elas contribuíram pouco para diferenciar os casos com e sem DPOC.

6.4 Limitações do Trabalho

Algumas limitações precisam ser consideradas. A primeira é que o diagnóstico de DPOC utilizado na pesquisa é autorreferido, ou seja, depende da informação dada pelo entrevistado e não de confirmação por espirometria ou exame clínico. Outra limitação é o forte desbalanceamento da base, já que poucos idosos relataram diagnóstico de DPOC. Além disso, como a PNS é uma pesquisa transversal, os resultados mostram associações entre as variáveis, mas não permitem afirmar relação de causa e efeito.

Também é importante destacar que os modelos foram avaliados em uma única divisão de treino e teste, sem validação externa em outra base de dados. Os intervalos de confiança das métricas também não foram calculados nesta versão do trabalho. Portanto, os resultados devem ser entendidos como uma análise exploratória, útil para identificar padrões e comparar modelos, mas que ainda precisa de validações adicionais para uso em outros contextos.

6.5 Trabalhos Futuros

Como trabalhos futuros, recomenda-se testar novas estratégias de validação, como reamostragem repetida ou bootstrap, para estimar intervalos de confiança das métricas. Também seria interessante aplicar outros modelos de aprendizado de máquina, incluir novas variáveis clínicas quando disponíveis e comparar os resultados com bases que tenham confirmação diagnóstica por espirometria.

7. Conclusão

Este trabalho teve como objetivo identificar fatores associados ao diagnóstico autorreferido de DPOC em idosos brasileiros, utilizando dados da Pesquisa Nacional de Saúde de 2019 e modelos de aprendizado de máquina. A base analisada apresentou forte desbalanceamento, com baixa proporção de casos positivos, o que tornou necessário avaliar os modelos com métricas além da acurácia, como recall, precisão, F1score e AUCROC.

A seleção de atributos por Information Gain ajudou a reduzir o conjunto de variáveis, mantendo aquelas com maior relação com a variável-alvo. Entre as variáveis mais relevantes, destacaram-se Q074, referente ao diagnóstico autorreferido de asma ou bronquite asmática, IMC, peso corporal, idade e variáveis ligadas a hábitos alimentares e atividade física. Esses resultados são coerentes com o tema estudado, pois envolvem histórico respiratório, estado nutricional e características do envelhecimento.

Na etapa inicial, o Random Forest apresentou maior AUC-ROC e maior recall em comparação com a Árvore de Decisão. Depois dos experimentos complementares, com inclusão do Balanced Random Forest e ajuste dos limiares de decisão, o Random Forest com limiar 0,4 apresentou o melhor F1-score para a classe DPOC=1. Por isso, ele foi considerado o modelo final com melhor equilíbrio entre precisão e sensibilidade. O Balanced Random Forest também teve papel importante, pois apresentou a maior AUC-ROC e mostrou boa capacidade de separação entre as classes.

De modo geral, os resultados indicam que modelos de aprendizado de máquina podem auxiliar na análise de fatores associados à DPOC em bases populacionais. No entanto, os achados devem ser interpretados com cuidado, pois os dados são autorreferidos e não substituem avaliação clínica. Mesmo assim, o estudo contribui ao

mostrar um pipeline completo, desde a seleção de variáveis até a comparação dos modelos, destacando a importância de lidar corretamente com bases desbalanceadas.

Referências

BIAU, G.; SCORNET, E. A random forest guided tour. *TEST*, v. 25, n. 2, p. 197–227, 2016.

CHEN, C.; LIAW, A.; BREIMAN, L. Using Random Forest to Learn Imbalanced Data. University of California, Berkeley, 2004.

CHAWLA, N. V. et al. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, v. 16, p. 321–357, 2002.

EXARCHOS, T. P. et al. A multi-scale and multi-parameter technique for the assessment of DPOC using clinical and spirometry data and decision trees. *BMC Medical Informatics and Decision Making*, v. 14, n. 1, p. 85, 2014.

GLOBAL INITIATIVE FOR CHRONIC OBSTRUCTIVE LUNG DISEASE (GOLD). Global Strategy for the Diagnosis, Management, and Prevention of Chronic Obstructive Pulmonary Disease: 2023 Report. 2023. Disponível em: <https://goldcopd.org>. Acesso em: maio 2025.

HE, H.; GARCIA, E. A. Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, v. 21, n. 9, p. 1263–1284, 2009.

IBGE — INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. Pesquisa Nacional de Saúde 2019: microdados. Rio de Janeiro: IBGE, 2020. Disponível em: <https://www.ibge.gov.br/pns2019>. Acesso em: maio 2025.

KOHANSAL, R. et al. The natural history of chronic airflow obstruction revisited: an analysis of the Framingham offspring cohort. *American Journal of Respiratory and Critical Care Medicine*, v. 180, n. 1, p. 3–10, 2009.

MENEZES, A. M. B. et al. Prevalência e fatores de risco para doença pulmonar obstrutiva crônica no Sul do Brasil: estudo PLATINO. *São Paulo Medical Journal*, v. 123, n. 4, p. 184–189, 2005.

MITCHELL, T. M. *Machine Learning*. New York: McGraw-Hill, 1997.

OLIVEIRA, B. L. C. A. et al. Fatores associados à autopercepção negativa de saúde em idosos brasileiros: análise da Pesquisa Nacional de Saúde 2013. *Ciência & Saúde Coletiva*, v. 26, n. 4, p. 1431–1444, 2021.